



**VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ**

BRNO UNIVERSITY OF TECHNOLOGY

**FAKULTA INFORMAČNÍCH TECHNOLOGIÍ**

FACULTY OF INFORMATION TECHNOLOGY

**ÚSTAV INTELIGENTNÍCH SYSTÉMŮ**

DEPARTMENT OF INTELLIGENT SYSTEMS

**DETEKCE ŽIVOSTI OTISKU PRSTU NA BEZDOTYKOVÉM ZAŘÍZENÍ**

LIVENESS DETECTION ON TOUCHLESS FINGERPRINT SCANNER

**BAKALÁŘSKÁ PRÁCE**

BACHELOR'S THESIS

**AUTOR PRÁCE**

AUTHOR

**KATEŘINA FOŘTOVÁ**

**VEDOUCÍ PRÁCE**

SUPERVISOR

**MONA HEIDARI**

**BRNO 2020**

## Abstrakt

Tato bakalářská práce je zaměřena na teorii biometrie, úvod do problematiky otisků prstů a některých algoritmů pro předzpracování a detekci živosti. Svoji implementaci těchto algoritmů jsem začala s využitím jazyka Python a knihovny OpenCV.

## Abstract

This Bachelor's Thesis is focused on theory of biometrics, introduction to fingerprint detection and some algorithms for pre-processing and liveness detection of fingerprints. I started implementation of these algorithms using Python and OpenCV library.

## Klíčová slova

biometrie, OpenCV, Python, detekce živosti, lokální binární vzor, zpracování obrazu

## Keywords

biometry, OpenCV, Python, liveness detection, local binary pattern, image processing

## Citace

FOŘTOVÁ, Kateřina. *Detekce živosti otisku prstu na bezdotykovém zařízení*. Brno, 2020. Bakalářská práce. Vysoké učení technické v Brně, Fakulta informačních technologií. Vedoucí práce Moná Heidari

# Detekce živosti otisku prstu na bezdotykovém zařízení

## Prohlášení

Prohlašuji, že jsem tuto bakalářskou práci vypracoval samostatně pod vedením vedoucí práce Mony Heidari a pana konzultanta Ing. Martina Sakina. Další informace mi poskytli...  
Uvedl jsem všechny literární prameny, publikace a další zdroje, ze kterých jsem čerpal.

.....

Kateřina Fořtová

14. března 2020

# Obsah

|          |   |           |
|----------|---|-----------|
| <b>1</b> | <b>Úvod</b>   | <b>3</b>  |
| <b>2</b> | <b>Biometrie</b>  | <b>4</b>  |
| 2.1      | Identita, identifikace, verifikace a autentizace . . . . .                          | 4         |
| 2.2      | Biometrické systémy . . . . .   | 5         |
| 2.3      | Skóre porovnání . . . . .   | 6         |
| 2.3.1    | Míra chybného přijetí (FAR) . . . . .   | 6         |
| 2.3.2    | Míra chybného odmítnutí . . . . .   | 6         |
| 2.3.3    | Souvislost FAR a FRR . . . . .  | 6         |
| <b>3</b> | <b>Detekce otisků prstů</b>   | <b>7</b>  |
| 3.1      | Historie . . . . .  | 7         |
| 3.2      | Zákony daktyloskopie . . . . .  | 7         |
| 3.3      | Struktura otisku prstu . . . . .  | 7         |
| 3.4      | Typy senzorů . . . . .  | 8         |
| 3.5      | Základní druhy markantů . . . . .   | 10        |
| 3.6      | Třídy otisků prstů . . . . .  | 11        |
| 3.7      | Falšování otisků prstů a výpočet přesnosti analýzy . . . . .                        | 12        |
| 3.8      | Známé metody pro analýzu živosti otisku prstu a výpočet přesnosti analýzy . . . . . | 12        |
| <b>4</b> | <b>Bezdotykový senzor a sběr datasetu</b>   | <b>13</b> |
| 4.1      | Popis bezdotykového senzoru . . . . .   | 13        |
| 4.2      | Sběr datasetu . . . . .   | 13        |
| <b>5</b> | <b>Průzkum současných řešení detekce živosti otisků prstů</b>                       | <b>15</b> |
| 5.1      | Hardwarové metody . . . . .   | 15        |
| 5.1.1    | Multispektrální analýza . . . . .   | 15        |
| 5.1.2    | Pulsní oxyometrie . . . . .   | 15        |
| 5.1.3    | Teplý a studený podnět . . . . .  | 15        |
| 5.1.4    | Teplota . . . . .   | 16        |
| 5.2      | Softwarové metody . . . . .   | 16        |
| 5.2.1    | Deformace kůže a elasticita . . . . .   | 16        |
| 5.2.2    | Detekce potu . . . . .  | 16        |
| <b>6</b> | <b>Využití algoritmy pro předzpracování a analýzu živosti otisků prstů</b>          | <b>17</b> |
| 6.1      | Převedení na normalizovaný obraz . . . . .  | 17        |
| 6.2      | Prahování . . . . .   | 18        |
| 6.2.1    | Prahování pomocí metody Otsu . . . . .  | 18        |

|          |  |           |
|----------|--|-----------|
| 6.2.2    | Adaptivní prahování . . . . .  | 18        |
| 6.3      | Segmentace . . . . .   | 19        |
| 6.4      | Lokální binární vzor (LBP) . . . . .   | 20        |
| 6.5      | Matice souvislostí stupňů šedi v obraze (GLCM) . . . . .                         | 21        |
| 6.6      | Vlnková transformace . . . . .   | 22        |
| 6.6.1    | Rodičovské a dceřinné vlnky . . . . .  | 23        |
| 6.6.2    | Spojitá vlnková transformace . . . . .   | 23        |
| 6.6.3    | Diskrétní vlnková transformace . . . . .   | 23        |
| 6.7      | Wavelet rodiny vhodné pro diskretní vlnkovou transformaci v analýze obrazu       | 24        |
| 6.7.1    | Vlnky Daubechies . . . . .   | 24        |
| 6.7.2    | Biortogonální spline vlnky . . . . .   | 25        |
| 6.7.3    | Reverzní biortogonální spline vlnky . . . . .                                    | 25        |
| 6.8      | Detektory hran Sobel a Laplaceův operátor . . . . .                              | 26        |
| <b>7</b> | <b>Klasifikační algoritmy pro rozhodování o živosti a neživosti otisku prstu</b> | <b>27</b> |
| 7.1      | Umělá neuronová síť . . . . .  | 27        |
| 7.2      | Algoritmy podpůrných vektorů (SVM) . . . . .                                     | 28        |
| 7.3      | Rozhodovací stromy . . . . .   | 30        |
| <b>8</b> | <b>Průběh implementace, experimenty a vyhodnocení</b>                            | <b>31</b> |
| 8.1      | Knihovna OpenCV . . . . .  | 31        |
| 8.2      | Knihovna scikit-learn . . . . .  | 31        |
| 8.3      | Knihovna PyWavelets . . . . .  | 32        |
| 8.4      | Implementace . . . . .   | 32        |
| 8.5      | Experimenty . . . . .  | 32        |
| 8.6      | Vyhodnocení . . . . .  | 32        |
| <b>9</b> | <b>Závěr</b>   | <b>33</b> |
|          | <b>Literatura</b>  | <b>34</b> |

# Kapitola 1

## Úvod

S rozvojem moderních technologií a komunikačních zařízení se stále více aktuální stává otázka bezpečnosti a ochrany dat. Zabezpečování údajů pomocí biometrie si získalo velký úspěch, zvláště díky snadnému přihlášení do systému a větší míře bezpečnosti jak například u hesel nebo různých několikamístných kódů. Není zde totiž potřeba si pamatovat údaje, stačí pouze použít svůj vlastní biometrický identifikátor, který bývá i bezpečnějším způsobem přihlášení nebo ochrany soukromých údajů.

Mnoho systémů dnes využívá zabezpečení pomocí otisku prstu. Přestože tento druh identifikace se nám může jevit jako opravdu spolehlivý, i tato metoda může být napadena. Zfalšované otisky prstů mohou být vyrobeny z různých syntetických materiálů, které nemusí být nijak moc nákladné. Je proto potřeba vytvořit algoritmus, který by mohl původ otisků prstů nějakým způsobem rozlišit a odhalit, zda je systém narušený útočníkem nebo se jedná o živý otisk prstu.

Ve své práci se zaměřuji na implementaci kombinace různých algoritmů pro detekci vitality otisku prstu. Jedná se o algoritmy, které se zaměřují na zpracování obrazu, úpravu obrazu a výzkum, jak se dané algoritmy chovají u obrázků falešných a přirozených otisků. Hlavním bodem analýzy je textura otisku prstu. Pro svůj výzkum jsem využila bezdotykový senzor, který poskytuje mnoho výhod, ve srovnání s klasickými dotykovými přístroji. Na daném senzoru probíhal sběr datasetu živých a falešných otisků prstů. Živé otisky mi poskytlo několik osob a falešné otisky byly vyrobeny z různých materiálů, poskytované naší fakultou. Pro práci s bezdotykovým senzorem bylo využito nasvicování prstů o světle různé vlnové délky. Na souborech získaných ze senzoru jsem poté testovala implementované algoritmy, zkoumala jejich chování a vyhodnocovala závěry.

Výsledná analýza se sestávala z porovnání metod analýzy textury obrazu, analýzy hran a využití různých metod vlnkové transformace. Klasifikace probíhala za pomoci umělých neuronových sítí, algoritmu SVM a rozhodovacích stromů. Součástí mé práce je porovnání jednotlivých klasifikačních metod. Dále jsem zkoumala, jaké nasvicované světlo (červené, zelené nebo modré) vykazovalo největší přesnost a spolehlivost při mém výzkumu.

## Kapitola 2


# Biometrie

Biometrie je věda rozpoznávání identity člověka na základě jeho fyzických a behaviorálních vlastností jako například tvář, otisk prstů, hlas nebo oční duhovka. [16] Slovo biometrie pochází z řeckých slov bios (život) a metron (měření). Biometrické identifikátory jsou v informatice používány pro přístupovou kontrolu a identifikaci. Skoro všechny identifikátory jsou kombinací anatomických a behaviorálních charakteristik. U otisku prstu je behaviorální složkou skutečnost, že každý uživatel použije skener otisku prstů v závislosti na svém chování. Záleží i například na úhlu přiložení prstu nebo znečištění povrchu prstu či senzoru. U identifikace tváře pak záleží i na změnách pramenících z chování člověka (např. změna životního stylu vedoucí ke změně tělesné váhy).[18]

### 2.1 Identita, identifikace, verifikace a autentizace

Identifikace, verifikace, identita a autentizace jsou základními čtyřmi pojmy, které biometrické systémy využívají a pracují s nimi.[6]

- **Identita** - Je jednoznačnou charakteristikou jedince. Rozlišujeme ji dále na:
  - **Fyzická identita** - Tato identita je pouze jedna jediná. Je definována naším vzhledem a chováním.
  - **Elektronická identita** - Těchto identit můžeme mít vytvořených nespočetně mnoho díky například více různým účtům na webové stránce.
- **Identifikace** - Složí pro zjištění identity osoby. Osoba předá systému svoji biometrickou vlastnost a ten musí na základě jejího vyhodnocení rozhodnout, zda je identita nalezená nebo nenalezená. Systém k tomuto účelu používá porovnávání s databází vzorků. Jedná se o porovnání 1:N, protože se biometrická vlastnost porovnává s celou databází.
- **Verifikace** - Uživatel sdělí systému svoji elektronickou identitu. V systému je pak potřeba ověřit skutečnou fyzickou identitu uživatele. Proto se hledá, zda-li jeho záznam obsahuje biometrická data. Dále se porovnává, zda sobě data odpovídají. Na základě tohoto údaje systém rozhodne o potvrzené či nepotvrzené identitě. Jedná se o porovnání 1:1, dochází k porovnání vstupních dat pouze s jedním záznamem v databázi.
- **Autentizace** - Systém při tomto úkonu potvrzuje autentičnost (hodnověrnost) dané osoby. Může být využita při identifikaci a verifikaci. Porovnávání většinou funguje na základě pomyslného prahu.

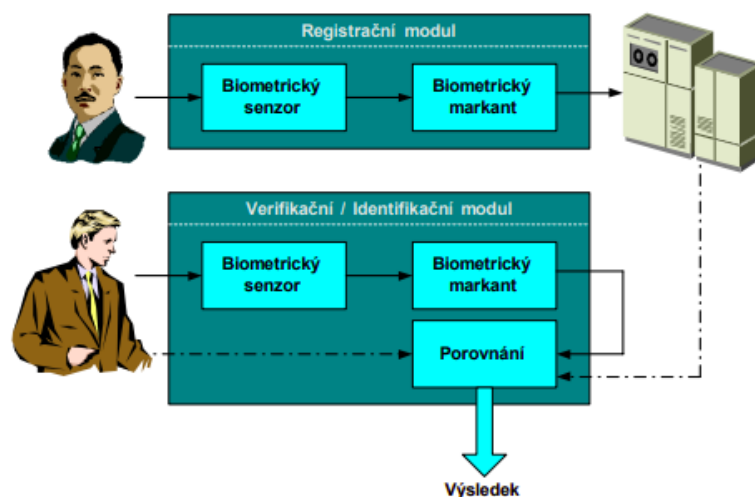


Obrázek 2.1: Rozdíl mezi identifikací a verifikací, převzato z [6]

## 2.2 Biometrické systémy

Biometrické systémy dělíme do dvou základních kategorií[6]:

- **Registrační modul** - Zde je zaregistrována biometrická informace (tzv. biometrický markant) a je uložena do databáze.
- **Verifikační modul** - Zde je zaregistrována biometrická informace podobně jako u registračního modulu, ale výsledek není uložen do databáze, nýbrž jsou data z databáze načítána, aby se extrahovaný biometrický markant mohl porovnat s daty v databázi.




Obrázek 2.2: Znázornění biometrického systému, převzato z [6]



## 2.3 Skóre porovnání

Skóre porovnání udává kvantifikovanou podobnost extrahovaného vzorku a šablony. Extrahovaný vzorek obsahuje významné rysy z vstupních dat. Šablona je pak uložena např. v databázi nebo na čipové kartě. Tato míra shody je založená na aplikaci prahu  $T$ , na základě kterého je rozhodnuto o přijetí nebo nepřijetí daného objektu.[6]



Obrázek 2.3: Skóre porovnání na základě zvoleného prahu, převzato z [6]

### 2.3.1 Míra chybného přijetí (FAR)

FAR (*False Acceptance Rate*) udává procentuální zastoupení identifikovaných instancí, kdy jsou neautorizované osoby akceptovány daným biometrickým systémem. Tato vlastnost je spočítána následujícím vzorcem:

$$FAR = \frac{\text{pocet prijatych neautorizovanych osob}}{\text{celkovy pocet testovanych vzorku}} * 100\%$$


### 2.3.2 Míra chybného odmítnutí

FRR (*False Rejection Rate*) představuje procentuální zastoupení identifikovaných instancí, kdy jsou autorizované osoby nekorektně biometrickým systémem zamítnuty. Výpočet je obdobný jako u charakteristiky FAR.

$$FRR = \frac{\text{pocet zamitnutych autorizovanych osob}}{\text{celkovy pocet testovanych vzorku}} * 100\%$$

### 2.3.3 Souvislost FAR a FRR

Vliv charakteristik FAR a FRR znázorňuje následující graf. S větší úrovní zabezpečení se snižuje FAR, čili je přijato stále méně a méně neautorizovaných osob. Naopak se zvyšuje riziko zamítnutí autorizovaných osob daným systémem. Průsečík těchto dvou křivek nese zkratku EER (*Equal Error Rate*) neboli Míra vyrovnaní chyb. V tomto bodě bude chybně akceptován a chybně odmítnut stejný počet osob. Můžeme mít systém, který je více bezpečný, ale méně uživatelsky přívětivý nebo obráceně.[31]



Obrázek 2.4: Souvislost charakteristik FAR a FRR, převzato z [31]

## Kapitola 3

# Detekce otisků prstů

Následující kapitola se zabývá základními informacemi o otiscích prstů. Po stručném shrnutí historie analýzy otisků prstů, jsem se zaměřila například na papilární linie, různé důležité markanty v otisku prstu nebo na typy senzorů, které se používají pro snímání.

### 3.1 Historie

Lidské otisky prstů byly objeveny na velkém počtu archeologických artefaktů a historických předmětů. I když tyto nálezy dokazují, že lidé si v té době byli vědomi unikátnosti otisků prstů, až v 16. století byla objevena první vědecká technika v jejich výzkumu. V roce 1864 anglický vědec Nehemiah Grew publikoval první vědeckou studii o hřebenech, rýhách a pórech v struktuře otisku prstu.

První detailní popis struktury otisků prstů byl předveden Mayerem v roce 1788. Purkinje pak roku 1823 vytvořil první klasifikační schéma, ve kterém otisky prstů rozdělil do devíti kategorií na základě konfigurace hřebenu.[18]

### 3.2 Zákony daktyloskopie

Daktyloskopie je naukou o obrazech papilárních linií. S touto vědou se pojí samotná identifikace daktyloskopických stop a osob.[27] Byly zavedeny tyto daktyloskopické zákony[6]:

- Struktura papilárních linií je unikátní pro každého jedince.
- Vzor tvořený papilárními liniemi je pro každého jedince během života relativně neměnný.
- Obnova papilárních linií probíhá dorůstáním kůže na povrchu prstů. Papilární linie mohou být pozměněny pouze pokud se poškodí nebo odstraní epidermální vrstva kůže. Poté již nemůže docházet k obnově.
- Konfigurační typy se mohou individuálně měnit, jedná se však o malé změny, které leží v tolerančních limitech a umožňují tak systematickou klasifikaci.

### 3.3 Struktura otisku prstu

Otisk prstu je tvořen vzorem papilárních linií. Výška papilárních je v rozmezí 0,1 - 0,4 mm a šířka v rozmezí 0,2 - 0,5 mm.[6] Průběhy papilárních linií jsou jedinečné pro každého člověka.

S přibývajícím věkem se mění rozměry plošek prstů či dlaní, avšak struktura papilárních linií zůstává stejná.

Nejvýznamější atributy papilárních linií se vyvíjí již v nitroděložní části života. Konečná podoba papilárních linií je u dítěte již v 6. - 7. měsíci nitroděložního vývoje.[7]

Otisky prstů dělíme na základní tři druhy:[6]

- Válený otisk (barvený, rolovaný)
- Píchaný otisk (živý)
- Latentní otisk (skrytý)




Obrázek 3.1: Válený, píchaný a latentní otisk prstu, převzato z [6]

### 3.4 Typy senzorů


Nejdůležitější částí detekce je senzor, který zaznamenává výsledný otisk prstu. Řadíme je do těchto základních kategorií:

- **Optické senzory** - Využívají jednoduchý zdroj světla (LED), které osvětlí plochu prstu.[6] Nejvíce používaným zástupcem optických senzorů je senzor FTIR. Prst se při snímání dotýká skleněného nebo plastového hranolu. Při dotyku jsou hřebeny papilárních linií v kontaktu s povrchem snímače, ale údolí jsou vzdálena. Světlo pocházející z hranolu dopadá na prst a je odraženo údolími papilárních linií nebo náhodně pohlceno hřebeny. Ve výsledném obrazu jsou pak hřebeny tmavá místa a údolí světlá místa. FTIR snímače dokáží snímat 3D otisk prstu a tak dokáží detekovat i zfalšované otisky prstu, které například pocházejí z fotografie. [18]




Obrázek 3.2: Senzor FTIR, převzato z [18]

- **Kapacitní senzory** - Jsou složeny z matice malých vodivých plošek, na níž je napařena vrstva nevodivého oxidu křemičitého.[6] Mezi povrchem prstu a každou z plošek (mikrokapacitorů) v čipu vzniká malý elektrický náboj. Při skládání výsledného otisku prstu je důležitá vzdálenost mezi povrchem otisku prstu a mikrokapacitorem. Hřebeny a údolí papilárních linií otisku prstu mají jinou vzdálenost od mikrokapacitoru, tudíž i odlišnou intenzitu ve výsledném obraze. Stejně jako u senzoru FTIR nemůže tato technologie být zneužita útočníkem při předložení fotografie. Jsou zde totiž měřeny vzdálenosti a pouze trojrozměrný povrch může být nasnímán.[18]




Obrázek 3.3: Kapacitní senzor, převzato z [18]

- **Ultrazvukové senzory** - Jsou založeny na posílání akustického signálu prstu a zachytávání odraženého signálu. Odražený signál je použit na výpočet hloubky obrazu a struktury papilárních linií. Senzor se skládá z vysílače a přijímače. Vysílač generuje krátké zvukové pulsy a přijímač detekuje odpověď po odražení těchto akustických pulsů od povrchu prstu. Senzor je schopný detekovat strukturu otisku prstu i např. přes tenké rukavice, stejně jako si dokáže poradit s nečistotami i mastnotou.[18]



Obrázek 3.4: Ultrazvukový senzor, převzato z [18]

- **Elektrooptické senzory** - Tyto snímače jsou složeny ze dvou vrstev. První dokáže emitovat světlo, pokud je polarizováno správným napětím. Druhá vrstva úzce spolupracuje s první, zpracovává emitované světlo a vytváří finální digitální obraz.[18]



Obrázek 3.5: Elektrooptický senzor, převzato z [18]


- **Tlakový senzor** - Je vytvořen z materiálu citlivého na mechanické namáhání, při kterém generuje elektrický signál. Velikost elektrického signálu závisí na tlaku, který vyvíjí prst na povrch senzoru. Hřebeny a údolí papilárních linií jsou v jiných vzdálenost od povrchu snímače, proto produkují jinou hodnotu elektrického signálu.[18]
- **Termický senzor** - Senzor využívá pyroelektrický materiál, který generuje elektrický náboj na základě teplotních rozdílů. Je založen na skutečnosti, že hřebeny v kontaktu s povrchem senzoru produkují jinou teplotu jak údolí, které jsou vzdálenější od povrchu snímače. Senzor je obvykle předeheřán na vyšší teplotu, aby se zvýšila odlišnost mezi povrchem zařízení a hřebeny linií.[18]

### 3.5 Základní druhy markantů

Otisk prstu obsahuje útvary, které tvoří papilární linie - markanty. Mezi důležité markanty patří:

- Ukončení (Line Ending)
- Jednoduchá vidlička (Simple Bifurcation)
- Dvojitá vidlička (Double Bifurcation)
- Trojitá vidlička (Triple Bifurcation)
- Hák (Hook)
- Křížení (Crossing)
- Boční kontakt (Side Contact)
- Bod (Point)
- Interval (Interval)
- Jednoduchá smyčka (Single Whorl)
- Dvojitá smyčka (Double Whorl)
- Jednoduchý most (Single Bridge)
- Dvojitý most (Twin Bridge)

- Průsečná linie (Through Line)




Obrázek 3.6: Základní typy markantů ve vyjmenovaném pořadí, převzato z [6]

U přístupových systémů se však využívá pouze ukončení (Line Ending) a vidličky (Bifuraction).[6]

### 3.6 Třídy otisků prstů

Otisky prstů můžeme na základě charakteristických znaků rozdělit do následujících kategorií:[6]

- Oblouk (Arch)
- Klenutý oblouk (Tended Arch)
- Spirála / závit (Whorl)
- Levá smyčka (Left Loop)
- Pravá smyčka (Right Loop)
- Dvojitá smyčka (Twin Loop)



Obrázek 3.7: Třídy otisků prstů, převzato z [6]

### 3.7 Falšování otisků prstů a výpočet přesnosti analýzy

Falešné biometrické reprezentace jsou obecně velkým nebezpečím, protože umožňují vydávat se zločinci za někoho jiného a tím narušit soukromí a bezpečnost jedince. Abnormální otisky prstů dělíme do dvou kategorií:

- Falešné otisky prstů
- Pozměněné otisky prstů

Falešný otisk prstu reprezentuje repliku skutečného otisku prstu vyrobeného softwarově nebo z materiálů jako je želatina, silikon nebo latex. Biometrické zařízení se musí rozhodnout, zda otisk je živý nebo falešný. Tato procedura se nazývá detekce živosti. Pozměněné otisky prstů jsou skutečné, avšak jejich struktura je změněna. Otisky mohou být neúplné, pokřivené. Důvodem poškození otisku mohou být nemoci kůže, např. pořezání, popálenina, poleptání silnými chemikáliemi, transplantace kůže a různé kožní nemoci.[26]

### 3.8 Známé metody pro analýzu živosti otisku prstu a výpočet přesnosti analýzy

Algoritmů pro detekci živosti otisku prstu byla objevena ve studiích celá řada. Některé z nich zahrnují:[1]

- Použití vlastnosti elasticity lidské kůže.
- Umístění senzoru na zachytávání pachu vedle senzoru pro detekci otisku prstu. Senzor pachu zaznamenával výsledný signál a byl tak schopen rozpoznat lidskou kůži od syntetických materiálů, jako např. latex, silikon nebo želatina.
- Kombinace statických vlastností při detekci živosti, bylo pracováno s histogramem, tloušťkou hřebenů papilárních linií, signálem detekovaným z hřebenů nebo hodnota výkonového frekvenčního spektra.

Další existující řešení pro analýzu živosti jsou uvedené v přímo zaměřené kapitole Průzkum současných řešení detekce živosti otisků prstů ([chapter 5](#)).

Přesnost analýzy živosti  $a$  můžeme spočítat na základě vzorce:  $a = \frac{C}{N}$ , kde  $C$  je počet správných rozhodnutí (klasifikace živého otisku prstu jako "živého" a falešného otisku prstu jako "falešného") a  $N$  je počet všech rozhodnutí.[11]

## Kapitola 4

# Bezdotykový senzor a sběr datasetu

Tato kapitola se zabývá popisem bezdotykového senzoru, který je základním přístrojem, se kterým jsem v rámci své bakalářské práce pracovala. Dále je zde popsán průběh sběru datasetu, jak byly otisky prstů snímány a také jaké falešné otisky byly použity.

### 4.1 Popis bezdotykového senzoru

Bezdotykový senzor je založen na typu snímání, kdy daný prst nepřichází do kontaktu s žádným povrchem, jako je to u dotykových senzorů. Díky kontaktu s daným povrchem se mohou obrazy otisku prstu od stejného objektu lišit. Dále je i použití dotykových senzorů otisků prstů mírně nehygienické v místech, kde ho denně použijí stovky nebo tisíce lidí. Dané povrchy pro analýzu jsou u dotykového senzoru ploché, ale sám povrch prstu plochý není. Objekt musí tedy použít jistý tlak na senzor, který dokáže výsledný obraz zkreslit. Bezdotykový senzor může sloužit k 2D i 3D snímání, při analýze je možné použít různé algoritmy pro analýzu textury nebo nasvícení světlem o různých vlnových délkách. [3]

Použitý bezdotykový senzor v rámci bakalářské práce je složen ze tří kamer a světel o různých vlnových délkách, které dokáží prst nasvítit. Pro výzkum byla použita prostřední kamera. Prsty byly nasvicovány modrým, zeleným a červeným světlem. Byly provedeny experimenty i s ultrafialovým zářením, ale toto světlo bylo velmi slabé, výsledky nebyly dobré a proto nebylo při výsledné analýze nakonec použito.


### 4.2 Sběr datasetu

Pro snímky živých otisků prstů bylo použito zhruba šest osob. Prsty byly nasvicovány jednotlivými světly. Bylo potřeba dbát na skutečnost, aby nebyly obrazy přesvětlené a vynikly tak co nejlépe dané papilární linie a textura povrchu prstu. I přes vynaloženou snahu, se mohou na snímcích objevit stíny, ale snažila jsem se co nejvíce simulovat skutečné používání senzoru, aby dokázal analyzovat živost s co největším rozpětím, v různých podmínkách a s robustností.


Zjistila jsem, že pro některé osoby bylo zpočátku trochu nezvyklé držet prst opravdu ve statické poloze při snímání, což беру jako mírnou nevýhodu bezdotykového senzoru.

Pro svoji analýzu jsem dále použila zhruba 36 falešných otisků prstů. I zde bylo potřeba dbát na co největší vyniknutí papilárních linií.





Obrázek 4.1: Obrázek živého otisku prstu s nasvícením modrým světlem




Obrázek 4.2: Obrázek živého otisku prstu s nasvícením zeleným světlem




Obrázek 4.3: Obrázek živého otisku prstu s nasvícením červeným světlem



Obrázek 4.4: Obrázek falešného otisku prstu s nasvícením modrým světlem



Obrázek 4.5: Obrázek falešného otisku prstu s nasvícením zeleným světlem



Obrázek 4.6: Obrázek falešného otisku prstu s nasvícením červeným světlem

## Kapitola 5

# Průzkum současných řešení detekce živosti otisků prstů

Algoritmů pro detekci živosti otisku prstu byla objevena ve studiích celá řada. Jedná se o práce, které využívají jak hardwarové metody analýzy, tak softwarové metody. Nevýhodou hardwarových metod je, že požadují zvláštní vybavení navíc. Tato kapitola popisuje stručně současné přístupy k analýze.

### 5.1 Hardwarové metody

Hardwarové metody využívají k určení živosti otisku prstů zvláštní hardwarová zařízení. Důležitým opatřením pro tyto metody je skutečnost, aby byly daná hardwarová zařízení integrována takovým způsobem, aby měření neohrozila kombinace útočnickova živého prstu s falešným. Zde jsou uvedeny některé z daných přístupů.

#### 5.1.1 Multispektrální analýza

Kůže člověka má některé unikátní optické charakteristiky díky chemickému složení, které ovlivňuje například absorpci optických vlastností. Díky snímkům nasvíceným světlem o různé vlnové délce, můžeme měřit různé vlastnosti lidské kůže a můžeme tedy odhalit případný falešný otisk prstu. Například modré světlo je rychle absorbováno prstem, vedle toho červené světlo prst prosvítí. Pomocí kamery je měřeno odražené světlo od nasvíceného prstu, měření může být poté vizualizováno do grafu a na základě výsledného spektra a matematických metod je stanoven výsledek.[8]

#### 5.1.2 Pulsní oxyometrie

Tato metoda využívá měření obsahu kyslíku v krvi. Využívá LED a fotodetektor na opačných stranách prstu. Měření závisí na srdečním tepu a proto může trvat několik sekund, než je spočten jeden nebo dva celé cykly srdečního tepu.[17]

#### 5.1.3 Teplý a studený podnět

Lidský prst dokáže odlišně reagovat na daný podnět, který je umístěný u senzoru. Výsledná informace je zaznamenána, konkrétně se jedná o kolísání rychlosti průtoku krve v periferních cévách. Při teplém podnětu se amplituda rychlosti toku zvyšuje, při studeném podnětu pak

snižuje. Tato metoda však může být ovlivněna citlivou lidskou periferní nervovou soustavou, kdy chvíli trvá, než správně zareaguje na teplý nebo studený podnět u daného člověka.[8]

#### 5.1.4 Teplota

Teplota lidské kůže u prstu se pohybuje okolo 25 - 37 stupňů Celsia. Nicméně tento rozsah musí být širší, aby mohl systém pracovat pod různými podmínkami, i díky lidem, kteří mají problém s cirkulací krve. Tato skutečnost však může vést k chybným rozhodnutím při této metodě. Dalším možným řešením je zahřátí prstu. Použitím falešného otisku dosáhneme rozdílu zhruba dvou stupňů Celsia. Rozdíl je tedy malý a tato metoda není dostatečně spolehlivou pro bezpečnou detekci živosti otisků prstů.[8]

### 5.2 Softwarové metody

Tyto metody užívají k detekci živosti informace, které jsou již obsažené v obrazu otisku prstu. Jedná se například o znaky deformace kůže, detekci pórů a další. Výhodou je, že tyto metody nemusí využívat žádné přídavné hardwarové zařízení a mohou být tedy i levnější na samotné nasazení.

#### 5.2.1 Deformace kůže a elasticita

Tyto techniky zkoumají, jak se deformuje lidská kůže, když je prst přitlačen na povrch senzoru. Bylo zjištěno, že živé prsty se na povrchu snímače chovají způsobem, kdy se u nich projevuje značné množství nelineárního zkreslení. Falešné prsty jsou více tuhé než kůže a deformace je nižší, dokonce i když jsou falešné otisky vyrobeny z vysoce elastických materiálů.[17]

#### 5.2.2 Detekce potu

I bříško prstu obsahuje potní žlázy, proto detekce pórů může posloužit pro analýzu živosti prstu. Na základě uběhnutého času se změří změna velikosti pórů, kdy se vzor stává postupně tmavším. Důležitou statickou charakteristikou je pak variabilita odstínů šedi okolo hřebenů papilárních linií. Dynamickou vlastností je pak vývoj v čase při změně extrahovaného signálu z hřebenů. Falešné snímky pak nedokáží pořádně poskytnout tyto vlastnosti kvůli neschopnosti provést hlavně dané dynamické vlastnosti, které jsou u živých prstů běžné.[24]



Obrázek 5.1: Srovnání vývoje detekce potu v čase mezi živým a falešným prstem, převzato z [24]


## Kapitola 6

# Využité algoritmy pro předzpracování a analýzu živosti otisků prstů


Tato kapitola se zabývá popisem použitých algoritmů pro předzpracování obrazu a následně vybraných algoritmů pro samotnou detekci živosti otisků prstů. Pro hlavní analýzu bylo algoritmů vybráno více. Samotná detekce se pak sestává z aplikace různých řešení a získání vlastností z samotného obrazu otisku prstu, které jsou použitelné pro rozlišení falešných a živých vzorků.

### 6.1 Převedení na normalizovaný obraz

Po načtení obrazu bylo potřeba obraz převést na šedotónový. Poté byla provedena normalizace obrazu. Normalizace je proces, při kterém je upraven rozsah hodnot intenzity pixelu. Základem je zvýšit dynamický rozsah šedotónového jasu, u otisků prstů tento algoritmus nemění ostrost hřebenů a údolí papilárních linií. Hlavním účelem je minimalizovat změny šedo-úrovňových hodnot podél hřebenů a údolí.



Obrázek 6.1: Šedotónový obraz živého otisku prstu



Obrázek 6.2: Normalizovaný obraz živého otisku prstu

## 6.2 Prahování

Při prahování jsou světlé objekty odděleny od tmavých pomocí zadaných prahů. Tento algoritmus je nutno použít před samotnou segmentací obrazu pomocí morfologických metod. Jednoduché prahování závisí na oddělení světlých a tmavých objektů podle daných konstantních prahů. Existují však i další metody prahování, které poskytují lepší analýzu a výsledky a při mém výzkumu byly použity.

### 6.2.1 Prahování pomocí metody Otsu

Při globálním prahování je nutné si vybrat konstantní práh již před analýzou obrazu. Metoda Otsu tento globální optimální práh vybírá sama automaticky, na základě daného vstupního obrazu. [23] Výpočet daného optimálního prahu zahrnuje iteraci přes všechny možné prahové hodnoty a výpočet rozložení pixelů na jednotlivých stranách prahu, pixelů, které spadají buď do popředí nebo pozadí obrazu. Účelem je pak najít hodnotu prahu, kdy součet rozložení na popředí a pozadí je na svém minimu. [13]


### 6.2.2 Adaptivní prahování

Adaptivní prahování slouží pro analýzu obrazu např. při situacích, kdy určité části obrazu mají jiné světelné podmínky, např. při výskytu stínů. Metoda nevyužívá konstantního prahu. Algoritmus určí pro pixel hodnotu prahu na základě malého okolí okolo něj. Výsledkem jsou jiné hodnoty prahů pro různé oblasti obrazu. Pro adaptivní prahování bylo využito následující metody: [23]

- Adaptivní průměrné prahování (*Adaptive Mean Thresholding*) - Hodnota prahu je průměrem okolí. Dále je od tohoto výsledku odečtena konstanta  $C$ .
- Adaptivní prahování Gaussian (*Adaptive Gaussian Thresholding*) - Výslednou hodnotu prahu udává vážená suma okolních hodnot, kdy váhy jsou Gaussian oknem. I zde je odečtena konstanta  $C$ .



Obrázek 6.3: Prahování pomocí metody Otsu



Obrázek 6.4: Prahování pomocí metody Gaussian



Obrázek 6.5: Prahování pomocí metody Mean


## 6.3 Segmentace

Při segmentaci vybereme z vstupního obrazu pouze otisk prstu, což nám napomáhá eliminovat pozadí obrazu. Bylo využito morfologického otevření - kombinace eroze a následné dilatace obrazu.


Morfologické operace se používají obvykle na úpravu binárního obrazu. Potřebují dva vstupy - náš vstupní obraz a jádro.[22] Tyto operace se používají často na obrazové předzpracování - odstraňují šum a zjednodušují tvary objektů. Eroze je morfologickou operací, která je užitečná pro odstranění malých bílých částí v obraze. Dilatace je opakem eroze a používá se k zaplnění mezer.[15]

Papilární linie jsou odděleny po vyprahování úzkými místy a tento algoritmus má za cíl úzká místa spojit a vytvořit tak masku, která bude určovat pozici otisku prstu v obraze. Struktura objektu se tedy při vzniku masky zjednoduší. Výsledná maska je následně aplikována na normalizovaný obraz a je tedy vybrána pouze část obrazu, která obsahuje otisk prstu, pozadí zůstává bílé.


Získaná maska vzniká prahováním, pro které byly využity tři výše zmíněné metody - metoda Otsu a dále adaptivní prahovací metody Mean a Gaussian.



Obrázek 6.6: Vstupní normalizovaný obraz




Obrázek 6.7: Získaná maska s využitím prahování pomocí Otsu metody



Obrázek 6.8: Výsledný segmentovaný obraz


Následující obrázky ukazují rozdílné výsledky segmentace s využitím různých prahovacích metod.



Obrázek 6.9: Segmentace při použití Otsu prahování



Obrázek 6.10: Segmentace při použití Gaussian prahování



Obrázek 6.11: Segmentace při použití Mean prahování

## 6.4 Lokální binární vzor (LBP)


Lokální binární vzor (*Local Binary Pattern* - LBP) je jedním z hlavních algoritmů, které byly využity pro analýzu v této práci. Jedná se o efektivní algoritmus, který se používá pro analýzu textury objektů. Algoritmus je užitečný pro informace o změnách intenzity mezi jednotlivými pixely obrázku a jejich sousedy. Vzorec pro lokální binární vzor vypadá následovně:[9]

$$LBP(x_c, y_c) = \sum_{n=0}^7 2^n (I_n - I(x_c, y_c)),$$


kde  $I_n$  jsou hodnoty sousedních pixelů,  $I(x_c, y_c)$  je hodnota středového pixelu a  $n$  je index souseda.

Postup algoritmu je následující:

1. Pro každý pixel je zjištěno okno o velikosti  $3 \times 3$  pixelů, kde námi procházený pixel  $x$  je středem, středem s danými osmi sousedy.
2. Pro každý pixel v  $3 \times 3$  okně je spočítána nová hodnota na základě tohoto pravidla - Pokud je hodnota zjišťovaného pixelu větší nebo rovna hodnotě středového pixelu, pak je novou hodnotou zjišťovaného pixelu 1, jinak 0.
3. Po spočítání nových hodnot celého  $3 \times 3$  okna je spočítána nová binární hodnota středového pixelu  $I(x_c, y_c)$ .



Obrázek 6.12: Okno o velikosti 9 pixelů se středovým pixelem a jeho sousedy pro analýzu lokálního binárního vzoru, převzato z [12]



Obrázek 6.13: Princip výpočtu lokálního binárního vzoru, upraveno s využitím [9]

Pro výpočet lokálního binárního vzoru byl použitý algoritmus, který lze zapsat následujícím pseudokódem:

**Data:** Předpracovaný obraz otisku prstu

**Result:** Obraz otisku prstu zpracován LBP a výsledný histogram

begin;

**for** *každý obrázek* **do**

**for** *každý pixel v obrazu* **do**

        zjistí pro každý pixel jeho sousední pixely v okně 3x3 vyjma krajních pixelů;

**for** *každý pixel v okně 3x3* **do**

            porovnej každý sousední pixel se středovým pixelem;

**if** *prostřední pixel > daný sousední pixel* **then**

                | nastav daný sousední pixel na 1;

**else**

                | nastav daný sousední pixel na 0;

**end**


**end**

**end**


        vygeneruj výsledný histogram obrazu;

**end**


Výsledný předzpracovaný obraz po aplikaci lokálního binárního vzoru může vypadat například následovně:



Obrázek 6.14: Falešný otisk prstu po aplikaci algoritmu LBP



Obrázek 6.15: Živý otisk prstu po aplikaci algoritmu LBP



Obrázek 6.16: Falešný otisk prstu po aplikaci algoritmu LBP

## 6.5 Matice souvislostí stupňů šedi v obraze (GLCM)

Matice GLCM (*Grey Level Cooccurrence Matrix*) slouží jako klasifikátor textury v obraze. Jedná se o čtvercovou matici, která vyjadřuje, jak často se určité kombinace hodnot pixelů v obraze vyskytují. Jedná se tedy o statistickou analýzu dané textury. Existuje až čtrnáct charakteristik, které jde z matice pro daný obraz zjistit. Pro svoji práci jsem využila čtyři z nich - kontrast, korelaci, energii a homogenitu.



Nechť  $L \times L$  reprezentuje matici GLCM, kde prvky na souřadnicích  $(i, j)$  reprezentují počet výskytů dvou sousedních pixelů, které mají hodnoty  $i$  a  $j$  v původním obraze.  $P_{i,j}$  představuje normalizovanou matici GLCM, proměnná  $levels$  dále počet stupňů šedi v obraze. Proměnné  $\mu_i$ ,  $\mu_j$ ,  $\sigma_i$  a  $\sigma_j$  charakterizují průměr a směrodatnou odchylku.[38]

Kontrast slouží pro měření intenzity mezi pixely a jeho sousedy v celém analyzovaném obraze. Jeho rozsah je  $< 0, (size(GLCM, 1) - 1)^2 >$ . Kontrast o hodnotě nula představuje konstantní obraz.[20][35]

$$contrast = \sum_{i,j=0}^{levels-1} P_{i,j}(i-j)^2$$

Korelace měří míru korelace pixelu ke svým sousedům. Nabývá hodnot v rozsahu  $< -1, 1 >$ . Tyto koncové míry charakterizují plně negativně nebo pozitivně korelovaný obraz.[20]Tuto charakteristiku můžeme spočítat podle následujícího vzorce:[35]

$$correlation = \sum_{i,j=0}^{levels-1} \left[ \frac{(i - \mu_i)(j - \mu_j)}{\sqrt{(\sigma_i^2)(\sigma_j^2)}} \right]$$

Energie počítá se sumou čtverců jednotlivých hodnot obsažených v GLCM matici. Výsledek energie leží v intervalu  $< 0, 1 >$ . Pro konstantní vstupní obraz má energie hodnotu 1. Jinak je tato vlastnost také nazývaná jako uniformita. Energie je založená na pravidelnosti, vysoké hodnoty představují obraz, který je pravidelně uspořádan.[20]

S pojmem energie úzce souvisí vlastnost ASM (*Angular Second Moment*), který se spočítá podle následující rovnice:[35]

$$ASM = \sum_{i,j=0}^{levels-1} P_{i,j}^2$$

Výsledná energie se pak spočte jako:[35]

$$energy = \sqrt{ASM}$$

Poslední extrahovanou charakteristikou byla homogenita. Tato vlastnost představuje blízkost distribuce prvků v GLCM matici ve srovnání s danou GLCM diagonálou. Homogenita může nabývat hodnot z rozsahu  $< 0, 1 >$ , kde homogenita s hodnotou jedna je typická pro diagonální GLCM matici.[20][35]

$$homogeneity = \sum_{i,j=0}^{levels-1} \frac{P_{i,j}}{1 + (i-j)^2}$$

## 6.6 Vlnková transformace

Vlnková transformace (*Wavelet transform*) je další z metod, které mohou být použity při klasifikaci živosti nebo např. při rozpoznávání. Jedná se o skupinu transformací, které se liší podle dané báze funkce - vlnky. Zadané vlnky jsou odvozené od základní funkce - mateřské vlnky (*mother wavelet*). Vlnková transformace je zástupcem lineární transformace. Signál (obraz) se analyzuje pomocí násobení funkcí okna a ortogonálním rozkladem, podobně jako dalších integrálních lineárních transformací.

Vlnková transformace může být využita také pro kompresi obrazu nebo pro filtraci šumu. [14] Obecně představuje alternativu ke krátkodobé Fourierově transformaci. Fourierova transformace byla velmi využívána v minulosti, ale nyní se více zaměřuje na víceměřítkové transformace (*Multiresolution Transform* - MT), ke kterým patří i vlnková transformace. Fourierova transformace využívá pro rozklad signálu do spektrální roviny periodické sinusové a kosinusové funkce, báze vlnkové transformace je tvořena časově omezenými funkcemi - vlnkami. Vlnky mohou být nadefinovány podle charakteru analyzovaných dat a můžeme dosáhnout i velmi přesné lokalizace průdkých změn v signálu a lepšího vyhodnocení v případě nestacionárních a neperiodických signálů.[2]

### 6.6.1 Rodičovské a dceřinné vlnky

Mateřská vlnka je základní vlnkovou funkcí. Určuje tvar vlnky a pokrývá celý definiční obor, který nás zajímá. Mateřskou vlnku značíme symbolem  $\Psi$ . Má nulovou střední hodnotu.

Otcovská vlnka pak poskytuje funkci určující měřítko, tvoří ze základní vlnky další s různým měřítkem a dovoluje vyjádřit detaily aproximované funkce, které zkoumáme. Otcovská vlnka se značí symbolem  $\Phi$ .

Odvozené vlnky nazýváme dceřinnými vlnkami. Tyto vlnky se odvozují od rodičovských vlnek za pomoci generující báze funkce  $\Psi_{s,\tau}$ , kde parametr  $s$  určuje měřítko vlnkové funkce a  $\tau$  pak posun dané vlnkové funkce.[14]

### 6.6.2 Spojitá vlnková transformace

Spojitá vlnková transformace (*Continuous Wavelet Transform* - CWT) lze zapsat následující rovnicí:[19]

$$y(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} x(t) \Psi^*\left(\frac{t-b}{a}\right) dt$$

Signál  $x(t)$  je korelován s vlnkami, které jsou odvozené od mateřské vlnky  $\Psi(t)$ . Symbol  $*$  je pak značením komplexně sdružené funkce. Výsledkem je funkce  $y(a, b)$ , kde parametr  $a$  určuje umístění vlnky na časové ose a parametr  $b$  pak měřítko. Konstanta  $\frac{1}{\sqrt{a}}$  pak slouží pro normalizaci energie vlnky při změnách měřítka.

Pro případ symetrické vlnkové funkce se postupně hledá míra korelace (podobnosti) mezi naším vstupním signálem a vlnkou s měnícím se měřítkem. Ve výsledku se tedy můžou extrahovat různé velké detaily z dat, které jsou zpracována.[2]

### 6.6.3 Diskrétní vlnková transformace

Diskrétní vlnková transformace (*Discrete Wavelet Transform* - DWT) pro svoje fungování nepotřebuje nadbytečné množství koeficientů, které produkuje právě spojitá vlnková transformace, ale koeficienty redukuje. Používají se koeficienty, které odpovídají měřítkům  $s = 2^j$ , kde parametr  $j$  může nabývat hodnot z množiny  $\{0, 1, 2, \dots, n\}$ . Díky vhodné dvojkové závislosti parametrů  $s$  a  $p$  můžeme vytvořit z vlnky  $\Psi$  ortonormální bázi. Nechť parametry  $j, k \in \mathbb{Z}$ , pak pro  $s$  a  $p$  platí:

$$s = 2^j$$

$$p = k2^j$$

Pak můžeme vzorec diskrétní vlnkové transformace napsat následujícím způsobem:

$$\Psi_{j,k} = \frac{1}{\sqrt{2^j}} \Psi\left(\frac{n - k2^j}{2^j}\right)$$

Diskrétní vlnková transformace při zpracování obrazu se využívá hlavně pro detekci hran a textur, kompresi, filtraci šumu a získání důležitých vlastností pro další klasifikaci.[2]

## 6.7 Wavelet rodiny vhodné pro diskrétní vlnkovou transformaci v analýze obrazu

Existuje mnoho druhů mateřských vlněk. Na základě mateřské vlnky můžeme odvodit celou danou rodinu. Vlnky mají různé vlastnosti:[30]


- Symetričnost
- Asymetričnost
- Ortogonálnost - Jedná se o vlnku, jejíž vlnková transformace je ortogonální, to znamená, že inverzní vlnková transformace je sdružená vlnkové transformaci.[21]
- Biortogonálnost - Vlastnost vlnky, kdy je daná vlnková transformace invertovaná, ale ne nutně ortogonální.

Pro diskrétní vlnkovou transformaci se používají například následující Wavelet rodiny.


### 6.7.1 Vlnky Daubechies

Jedná se o asymetrické, ortogonální a biortogonální vlnky. Značí se jako  $dbA$ , kde  $A$  vyjadřuje počet nulových momentů. Pro práci můžeme využít Daubechies  $db1$  až  $db20$ , běžně užívány jsou však vlnky typu  $db1$  až  $db10$ . [30] Dosahují vysoké míry komprese. Poskytují stejné parametry filtrů pro přímou i zpětnou transformaci, zajišťují rychlou a přesnou rekonstrukci.[14]

Každá Daubechies vlnka má počet nulových momentů rovných polovině svých koeficientů. Například vlnka  $db1$  (také jinak zvaná jako Haar vlnka) má jeden nulový moment,  $db2$  pak dva nulové momenty, atd. Nulový moment určuje schopnost vlnky reprezentovat chování polynomu nebo informace v signálu. Například vlnka  $db1$  s jedním nulovým momentem snadno kóduje konstantní složky signálu. Daubechies vlnka  $db2$  snadno pracuje s konstantními a lineárními signálovými složkami,  $db3$  pak pracuje s konstantními, lineárními a kvadratickými složkami signálu.[4]




Obrázek 6.17: Vlnková funkce pro vlnku Daubechies  $db2$ , převzato z [30]




Obrázek 6.18: Vlnková funkce pro vlnku Daubechies  $db4$ , převzato z [30]

### 6.7.2 Biortogonální spline vlnky

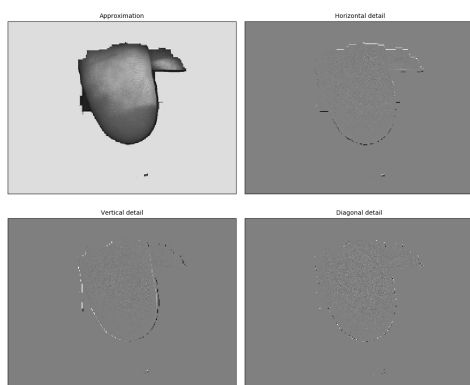
Biortogonální spline vlnky jsou symetrické, biortogonální, ale nejsou ortogonální. Pro analýzu můžeme využít vlnky *bior1.1*, *bior1.3*, *bior1.5*, *bior2.2*, *bior2.4*, *bior2.6*, *bior2.8*, *bior3.1*, *bior3.3*, *bior3.5*, *bior3.7*, *bior3.9*, *bior4.4*, *bior5.5* a *bior6.8*. [30] Jinak se také nazývají jako Cohen–Daubechies–Feauveau vlnky. Liší se vlastnostmi a tvarem od vlnek Daubechies, ale princip konstrukce vlnek je podobný. Biortogonální spline vlnky jsou generovány pomocí B-splinu. [37] Jsou využity ve standardu komprese obrazu JPEG 2000, dále se používají například při kompresi otisků prstů pro FBI.



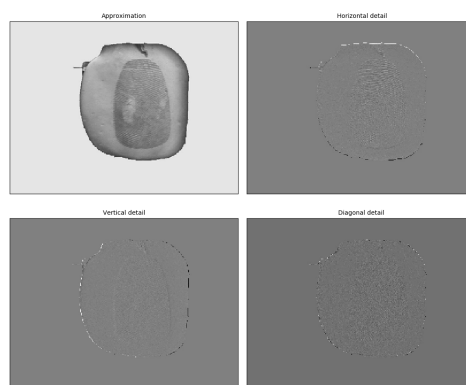
Obrázek 6.19: Dekompoziční vlnková funkce pro *bior1.3*, převzato z [30]



Obrázek 6.20: Dekompoziční vlnková funkce pro *bior2.4*, převzato z [30]




Obrázek 6.21: Vlnková transformace *bior1.5* pro živý otisk prstu



Obrázek 6.22: Vlnková transformace *bior1.5* pro falešný otisk prstu

### 6.7.3 Reverzní biortogonální spline vlnky

Reverzní biortogonální spline vlnky jsou symetrické, biortogonální a nejsou ortogonální. Pro práci můžeme využít tyto vlnky z dané rodiny - *rbio1.1*, *rbio1.3*, *rbio1.5*, *rbio2.2*, *rbio2.4*, *rbio2.6*, *rbio2.8*, *rbio3.1*, *rbio3.3*, *rbio3.5*, *rbio3.7*, *rbio3.9*, *rbio4.4*, *rbio5.5* a *rbio6.8*. [30] Tato rodina vlnek byla v minulém výzkumu využita například pro rozpoznávání oční duhovky. [36]




Obrázek 6.23: Dekompoziční vlnková funkce pro rbio2.4, převzato z [30]

## 6.8 Detektory hran Sobel a Laplaceův operátor


Sobel a Laplaceův operátor jsou vhodným řešením detekce hran v obrazu a tedy také popisem textury. Umožňují rychlé a snadné řešení jak snížit počet dat - pixelů pro analýzu a zvýraznit strukturální aspekt vstupního obrazu.

Sobel operátor je metoda založená na gradientu. Principem je spočítání derivací 1. řádu pro obraz při ose  $x$  a ose  $y$ . Získáme tak dva odlišné výsledky, se kterými můžeme dále pracovat. Pro analýzu bylo využito jádro (kernel) o velikosti  $5 \times 5$ , které se využívají pro aproximování daných výsledků - derivací 1. řádu, protože samotný obraz není spojitý.


Laplaceův operátor využívá pouze jedno jádro. Získáme jeden finální výsledek, ne dva výsledky pro osu  $x$  a  $y$  jako u předchozího detektoru hran.[34]




Obrázek 6.24: Výsledek aplikace Sobel operátoru pro osu  $x$  živého otisku prstu



Obrázek 6.25: Výsledek aplikace Sobel operátoru pro osu  $y$  živého otisku prstu




Obrázek 6.26: Výsledek aplikace Laplaceova operátoru pro živý otisk prstu



Obrázek 6.27: Výsledek aplikace Sobel operátoru pro osu  $x$  falešného otisku prstu



Obrázek 6.28: Výsledek aplikace Sobel operátoru pro osu  $y$  falešného otisku prstu



Obrázek 6.29: Výsledek aplikace Laplaceova operátoru pro falešný otisk prstu


## Kapitola 7

# Klasifikační algoritmy pro rozhodování o živosti a neživosti otisku prstu

Pro samotné rozhodnutí o živosti či neživosti otisku prstu je potřeba navrhnout a použít některý z klasifikátorů, které jsou založeny na bázi umělé inteligence. Pro vlastní výzkum jsem použila neuronovou síť, klasifikátor SVM (Support Vector Machine) a rozhodovací stromy. Tato kapitola popisuje stručný úvod do umělé inteligence a popisy jednotlivých přístupů.

### 7.1 Umělá neuronová síť

Umělá neuronová síť byla sestavena jako abstrakce podobná lidskému myšlení. Umělý neuron se nazývá perceptron a byl inspirován právě nervovou buňkou - neuronem. Výstupní signály umělých neuronů jsou statické na rozdíl od těch skutečných. Obecné schéma umělého neuronu je znázorněno na následujícím obrázku, proměnná  $u$  představuje vnitřní potenciál,  $f$  pak bázovou funkci,  $g$  aktivační funkci,  $i$  hodnotu daného vstupu a  $w$  váhu:



Obrázek 7.1: Obecný model umělého neuronu, převzato z [39]


Každá neuronová síť funguje na následujícím principu: Váhy se vynásobí s daným vstupem, dále probíhá přičtení speciální hodnoty zvané bias. Poté se aplikuje daná aktivační funkce a vstup se předá další vrstvě. Provádí se zpětná propagace, při které se aktualizují váhy. Vnitřní stav sítě můžeme tedy charakterizovat následujícím předpisem:  $w_0x_0 + \sum_{i=1}^n P_{i,j}w_ix_i$ , kde bias představuje prvek s hodnotou  $x_0$  a s vahou  $w_0$  a proměnné

$x_1, x_2, \dots, x_i$  představují vstupní hodnoty s danými vahami  $w_1, w_2, \dots, w_i$ . V některých případech může být výstup daných hodnot velmi velký, pokud pracujeme s více vrstvami neuronové sítě, hodnoty se mohou stále stávat vyššími a vyššími a samotný výpočet pak nekontrolovatelným. Proto hraje důležitou roli aktivační funkce, která na výstupu pracuje s hodnotami v určitém intervalu, např.  $(-1, 1)$  nebo  $(0, 1)$ . [28]

V rámci bakalářské práce jsem jako aktivační funkci využila sigmoidu. Jedná se o nelineární funkci, která nabývá hodnot v intervalu  $(0, 1)$ , proto je vhodná pro modely, kde máme předpovědět pravděpodobnost vstupu. Rovnice funkce je následující:

$$f(x) = \frac{1}{1 + e^{-x}}$$

Sigmoida je snadno diferencovatelná, můžeme ji lehce použít pro aktualizaci daných vah.



Obrázek 7.2: Graf sigmoidy a její derivace, převzato z [28]

Zderivovaná sigmoida má pak následující předpis:

$$g(x) = e^{-x} * (1 + e^{-x})^{-2}$$


Dále pro sigmoidu a její derivaci platí následující pravidlo:

$$\frac{df(x)}{f(x)} = f(x) * (1 - f(x))$$


## 7.2 Algoritmy podpůrných vektorů (SVM)

Algoritmy podpůrných vektorů (*Support Vector Machines*) jsou další metodou strojového učení sloužící pro klasifikaci. Principem algoritmu je nalézt nadrovinu pro členění daných vektorů. Data určená pro trénování, u kterých víme, jaké mají výsledky, slouží právě pro nalezení optimální nadroviny, která potom rozdělí do kategorií testované vzorky, u kterých předpovídáme výsledek. V dvourozměrném prostoru je nadrovina přímka, která dělí rovinu na dvě části (poloroviny), kdy vzorky z jedné třídy leží v jedné polorovině, vzorky druhé třídy pak v druhé polorovině.


Pokud není možné vzorky rozumně rozdělit polorovinou, aplikujeme transformaci a přidáme jeden další rozměr, osu  $z$ . Necht' hodnoty bodů na ose  $z$  mají hodnotu  $w = x^2 + y^2$ . V tomto případě můžeme měnit vzdálenosti bodu od osy  $z$ . Pokud nyní načtneme graf o souřadnicích  $yz$ , vidíme zde rozdělení, které můžeme zase oddělit přímkou.



Obrázek 7.3: Příklad problému v dvourozměrném prostoru a nalezení optimální nadroviny a rozpětí, převzato z [5], na které se podílel jeden z původních výzkumníků algoritmu



Obrázek 7.4: Vstupní vzorky, které není možné rozdělit polorovinou, převzato z [25]



Obrázek 7.5: Graf o souřadnicích  $yz$  s rozdělením na dané poloroviny, převzato z [25]


Pokud zpět transformujeme tuto přímku do grafu o závislosti osy  $y$  na ose  $x$ , vzorky jsou nyní rozděleny hranicí ve tvaru kružnice. Tato transformace se nazývá jádrová transformace. Slouží tedy pro převedení lineárně neseparovatelné úlohy na úlohu, která je již lineárně separovatelná a můžeme tedy nalézt finální rozdělující nadrovinu.[25]

Výhodami SVM jsou:[33]

- Jedná se o efektivní metodu v prostorech o více dimenzích.
- SVM je efektivní i při případech, kdy počet dimenzí je větší než počet vzorků.
- Jedná se o paměťově efektivní algoritmus.

Je však na druhou stranu nevýhodou, že pokud je počet vlastností o mnoho vyšší jak počet vzorků, nemusíme dostávat tolik přesné výsledky.





Obrázek 7.6: Nalezení finální rozdělující nadroviny, převzato z [25]

### 7.3 Rozhodovací stromy

Cílem dalšího z klasifikačních algoritmů, rozhodovacích stromů (*Decision Trees* - DTs) je předpovědět výsledek na základě jednoduchých rozhodovacích pravidel, které jsou odvozené od vlastností dat. Tato klasifikační metoda tedy pro svoji práci využívá graf, který můžeme označit jako strom, protože je souvislý a neobsahuje žádnou kružnici. Cesty od kořene k listu reprezentují klasifikační pravidla.

Výhody rozhodovacích stromů jsou:[32]

- Jednoduché na pochopení a vizualizaci, stromy jde také vizualizovat.
- Vstupní data nemusí být různě upravována nebo normalizována.
- Používá model white box - bílou skříňku. Pokud je daná situace v modelu pozorovatelná, vysvětlení pro podmínky může být snadno vysvětleno pomocí boolovské logiky. Umělá neuronová síť je reprezentantem modelu black box - černé skříňky, kdy mohou být výsledky obtížnější interpretovat.

Algoritmus však může v některých případech vytvořit až příliš komplexní strom, který data špatně zpracovává a generalizuje. Tato situace se nazývá overfitting. Jedná se tedy o chybu v modelování, kdy je model příliš složitý a funkce je příliš kompatibilní s omezenou sadou datových bodů. Při nepatrně nepřesných údajích může finální model získat podstatné chyby a predikce může být pak nepřesná.

## Kapitola 8

# Průběh implementace, experimenty a vyhodnocení

Cílem samotné implementace bylo aplikovat algoritmy pro předzpracování obrazu a následně využít postupy, které mohou zajistit na základě analýzy textury výsledné rozhodnutí o živosti či neživosti daného otisku prstu. Pro implementaci byl využit jazyk Python 3.6 s dalšími podporovanými knihovnami. Pro vývoj bylo použito prostředí operačního systému Ubuntu 18.04.4 LTS.

### 8.1 Knihovna OpenCV

OpenCV je open-source knihovna, která slouží pro práci s obrazem a získávání důležitých dat. Vedle programovacího jazyka Python může být využita například i s jazykem Java nebo C++. Samotná knihovna byla napsána v jazyce C/C++.[10] Vedle práce s obrazem nabízí tato knihovna například i práci s kamerami, která byla využita například při získávání dat ze senzoru. Tato knihovna byla využita při práci s otisky prstů, její funkce byly nápomocny při předzpracování obrazu a dále napomáhala i při implementaci algoritmu pro lokální binární vzor.

### 8.2 Knihovna scikit-learn

Ekvivalentem pro knihovnu OpenCV je knihovna scikit-learn, která však umožňuje pouze podporu pro jazyk Python. Tato knihovna se primárně specializuje na podporu strojového učení, obsahuje však i funkce na podporu analýzy obrazu. Byla nápomocná při extrahování matice GLCM z obrazu, jejíž některé vlastnosti byly klíčové pro extrahovaný vektor při všech uvažovaných a zkoumaných formách analýzy. Pro klasifikaci pak byla využita funkce pro metodu SVM a taky pro rozhodovací strom. Knihovna scikit-learn představuje snadnou práci s algoritmy umělé inteligence, algoritmy jsou dobře optimalizované a rychlé. Umožňuje experimenty s různými metodami a přístupy, na základě kterých může člověk uvážit co nejvíce metod klasifikace, které mezi sebou můžeme porovnat a zkoumat chování v různých podmínkách.

### 8.3 Knihovna PyWavelets

Knihovna PyWavelets představuje open source knihovnu umožňující vlnkové transformace pro práci v jazyce Python. Knihovna je částečně implementována v jazyce C. Knihovna poskytuje 1D či 2D diskrétní vlnkovou transformaci a také 1D spojitou vlnkovou transformaci. Obsahuje více jak 100 vestavěných vlnkových filtrů a podporuje i tvorbu vlastních vlnek pro uživatele. Poskytuje co nejpřesnější výsledky. Výsledky jsou kompatibilní například z Matlab Wavelet Toolbox (TM) v programovacím jazyce Matlab.

Knihovna byla využita pro diskrétní vlnkovou transformaci analyzovaných otisků prstů. Vedle využitých vlnkových rodin (biortogonální spline vlnky, reverzní biortogonální spline vlnky, vlnky Daubechies) poskytuje pro možnou analýzu i další vlnkové rodiny jako např. Symlety nebo Coiflety.[\[29\]](#)

### 8.4 Implementace

### 8.5 Experimenty

### 8.6 Vyhodnocení

## Kapitola 9

# Závěr

V průběhu zimního semestru jsem se v rámci povinného předmětu Semestrální projekt (ITT) začala seznamovat s tématem detekce živosti otisků prstů. Nastudovala jsem odborné články a literaturu, začala jsem pracovat na algoritmech pro předzpracování obrazu (normalizace, prahování, ztenčování linií, extrakce orientovaného pole, extrakce markantů). Začala jsem implementovat hlavní algoritmus pro detekci živosti - lokální binární vzor. V průběhu letního semestru budu svoji práci dále rozšiřovat a zdokonalovat, chci provést výzkum nejen softwarově generovaných otisků prstů, ale i otisků prstů z různých syntetických materiálů. Plánuji navštívit laboratoř a získat snímky syntetických otisků prstů z senzoru, dále se pak chci pokusit z lokálního binárního vzoru vyextrahovat další užitečné informace kromě histogramu. Svoji detekci živosti prstu chci vedle extrakce markantů a lokálního binárního vzoru rozšířit také o práci s vlnovou délkou. Jednotlivé algoritmy poté porovnáám na základě přesnosti či rychlosti zpracování.

# Literatura

- [1] ABISHEK, K. *A Minutiae Count Based Method for Fake Fingerprint Detection* [online]. 2015 [cit. 2019-11-23]. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S1877050915021729>.
- [2] ANISIMOVA, E., BEDNÁŘ, J. a PÁTA, P. *Zpracování obrazu pomocí vlnkové transformace* [online]. 2013 [cit. 2020-03-04]. Dostupné z: <http://www.elektrorevue.cz/cz/download/zpracovani-obrazu-pomoci-vlnkove-transformace--image-processing-using-the-wavelet-transform-/>.
- [3] BAI, X., HANCOCK, E. R., HO, T. K., WILSON, R. C., BIGGIO, B. et al. *Structural, Syntactic, and Statistical Pattern Recognition*. 1. vyd. Springer, 2006. ISBN 978-3-540-37236-3.
- [4] BULTHEEL, A. a HUYBRECHS, D. *Wavelets with applications in signal and image processing* [online]. 2014 [cit. 2020-03-05]. Dostupné z: <https://people.cs.kuleuven.be/~daan.huybrechs/teaching/wavelets2014.pdf>.
- [5] CORTES, C. a VAPNIK, V. *Support-Vector Networks* [online]. 1995 [cit. 2020-03-03]. Dostupné z: [http://image.diku.dk/imagecanon/material/cortes\\_vapnik95.pdf](http://image.diku.dk/imagecanon/material/cortes_vapnik95.pdf).
- [6] DRAHANSKÝ, M. *Biometrické systémy - Studijní opora* [online]. 2006 [cit. 2019-11-16]. Dostupné z: [https://www.fit.vutbr.cz/study/courses/BIO/private/BIO\\_Studijni\\_opora.pdf](https://www.fit.vutbr.cz/study/courses/BIO/private/BIO_Studijni_opora.pdf).
- [7] DRAHANSKÝ, M., BŘEZINOVÁ, E., ORSÁG, F. a HEJTMÁNKOVÁ, D. *Dermatologické faktory ovlivňující snímání otisků prstů* [online]. 2010 [cit. 2019-11-17]. Dostupné z: <https://www.mvcr.cz/clanek/dermatologicke-faktory-ovlivnujici-snimani-otisku-prstu.aspx>.
- [8] DRAHANSKÝ, M. et al. *Advanced Biometric Technologies*. 1. vyd. InTech - Open Access Publisher, 2011. ISBN 978-953-307-487-0.
- [9] GAIKWAD, A. *Evaluation of Fingerprint Identification Based on Local Binary Pattern (LBP)* [online]. 2018 [cit. 2019-11-29]. Dostupné z: [https://www.researchgate.net/publication/327262459\\_Evaluation\\_of\\_Fingerprint\\_Identification\\_Based\\_on\\_Local\\_Binary\\_Pattern\\_LBP](https://www.researchgate.net/publication/327262459_Evaluation_of_Fingerprint_Identification_Based_on_Local_Binary_Pattern_LBP).
- [10] GEEKSFORGEEKS. *OpenCV – Overview* [online]. 2017 [cit. 2020-02-02]. Dostupné z: <https://www.geeksforgeeks.org/opencv-overview/>.
- [11] GOTTSCHLICH, C., MARASCO, E., YANG, A. a CUKIC, B. *Fingerprint Liveness Detection based on Histograms of Invariant Gradients* [online]. 2014 [cit. 2019-12-02].

- Dostupné z: [https://www.researchgate.net/publication/265733920\\_Fingerprint\\_Liveness\\_Detection\\_based\\_on\\_Histograms\\_of\\_Invariant\\_Gradients](https://www.researchgate.net/publication/265733920_Fingerprint_Liveness_Detection_based_on_Histograms_of_Invariant_Gradients).
- [12] GRAGNANIELLO, D. *Local image descriptors for biometric liveness detection* [online]. 2015 [cit. 2019-11-28]. Dostupné z: <https://pdfs.semanticscholar.org/e96d/5c8299ebfe60c9e4cc4fab07f2d7953908a0.pdf>.
  - [13] GREENSTED, A. *Otsu Thresholding* [online]. 2010 [cit. 2020-03-03]. Dostupné z: <http://www.labbookpages.co.uk/software/imgProc/otsuThreshold.html>.
  - [14] HLAVÁČ, V. *Vlnková transformace* [online]. 2015 [cit. 2020-03-04]. Dostupné z: <http://people.ciirc.cvut.cz/~hlavac/TeachPresCz/11DigZpr0br/14WaveletsCz.pdf>.
  - [15] HORÁK, K. *Morfologické operace* [online]. 2017 [cit. 2019-11-21]. Dostupné z: [http://midas.uamt.feec.vutbr.cz/ZVS/Exercise10/content\\_cz.php](http://midas.uamt.feec.vutbr.cz/ZVS/Exercise10/content_cz.php).
  - [16] JAIN, A. K., FLYNN, P. a ROSS, A. A. *Handbook of Biometrics*. 1. vyd. Springer, 2008. ISBN 978-0-387-71040-2.
  - [17] LI, S. Z. et al. *Encyclopedia of Biometrics*. 1. vyd. Springer, 2009. ISBN 978-0-387-73003-5.
  - [18] MALTONI, D., MAIO, D., JAIN, A. K. a PRABHAKAR, S. *Handbook of Fingerprint Recognition*. 2. vyd. Springer, 2009. ISBN 978-1-84882-253-5.
  - [19] MATHWORKS. *Continuous Wavelet Transform and Scale-Based Analysis* [online]. 2019 [cit. 2020-03-04]. Dostupné z: <https://www.mathworks.com/help/wavelet/gs/continuous-wavelet-transform-and-scale-based-analysis.html>.
  - [20] MATHWORKS. *Graycoprops - Properties of gray-level co-occurrence matrix* [online]. 2020 [cit. 2020-02-17]. Dostupné z: <https://www.mathworks.com/help/images/ref/graycoprops.html>.
  - [21] MORSCHE, H. ter. *Wavelet basics* [online]. 2019 [cit. 2020-03-05]. Dostupné z: [https://www.win.tue.nl/casa/meetings/seminar/previous/\\_index\\_files/wavelets1.pdf](https://www.win.tue.nl/casa/meetings/seminar/previous/_index_files/wavelets1.pdf).
  - [22] OPENCV. *Morphological Transformations* [online]. 2019 [cit. 2019-11-21]. Dostupné z: [https://docs.opencv.org/trunk/d9/d61/tutorial\\_py\\_morphological\\_ops.html](https://docs.opencv.org/trunk/d9/d61/tutorial_py_morphological_ops.html).
  - [23] OPENCV. *Image Thresholding* [online]. 2020 [cit. 2020-03-03]. Dostupné z: [https://docs.opencv.org/3.4/d7/d4d/tutorial\\_py\\_thresholding.html](https://docs.opencv.org/3.4/d7/d4d/tutorial_py_thresholding.html).
  - [24] PARTHASARADHI, S., DERAKHSHANI, R. a HORNAK, L. A. *Time-Series Detection of Perspiration as a Liveness Test in Fingerprint Devices* [online]. 2005 [cit. 2020-02-11]. Dostupné z: [https://www.researchgate.net/publication/3421630\\_Time-Series\\_Detection\\_of\\_Perspiration\\_as\\_a\\_Liveness\\_Test\\_in\\_Fingerprint\\_Devices](https://www.researchgate.net/publication/3421630_Time-Series_Detection_of_Perspiration_as_a_Liveness_Test_in_Fingerprint_Devices).
  - [25] PATEL, S. *Chapter 2 : SVM (Support Vector Machine) — Theory* [online]. 2017 [cit. 2020-03-02]. Dostupné z: <https://medium.com/machine-learning-101/chapter-2-svm-support-vector-machine-theory-f0812effc72>.
  - [26] PETROVICI, A. a LAZAR, C. *Identifying Fingerprint Alteration Using the Reliability Map of the Orientation Field* [online]. 2010 [cit. 2019-11-17]. Dostupné z: [http://ace.ucv.ro/analele/2010\\_vol1/08Petrovici\\_Lazar.pdf](http://ace.ucv.ro/analele/2010_vol1/08Petrovici_Lazar.pdf).

- [27] POLICIE. *Kriminalistická daktyloskopie* [online]. 2017 [cit. 2020-02-02]. Dostupné z: <https://www.policie.cz/clanek/kriminalisticka-daktyloskopie-266095.aspx>.
- [28] PUSULURI, S. *Activation functions and weight initialization in deep learning* [online]. 2019 [cit. 2020-02-17]. Dostupné z: <https://medium.com/@sakeshpusuluri123/activation-functions-and-weight-initialization-in-deep-learning-ebc326e62a5c>.
- [29] PYWAVELETS. *PyWavelets - Wavelet Transforms in Python* [online]. 2020 [cit. 2020-03-10]. Dostupné z: <https://pywavelets.readthedocs.io/en/latest/>.
- [30] PYWAVELETS. *Wavelet Properties Browser* [online]. 2020 [cit. 2020-03-05]. Dostupné z: <http://wavelets.pybytes.com/family/db/>.
- [31] RECOGTECH. *FAR and FRR: security level versus user convenience* [online]. 2017 [cit. 2020-02-11]. Dostupné z: <https://www.recogtech.com/en/knowledge-base/security-level-versus-user-convenience>.
- [32] SCIKITLEARN. *1.10. Decision Trees* [online]. 2020 [cit. 2020-03-03]. Dostupné z: <https://scikit-learn.org/stable/modules/tree.html>.
- [33] SCIKITLEARN. *1.4. Support Vector Machines* [online]. 2020 [cit. 2020-03-03]. Dostupné z: <https://scikit-learn.org/stable/modules/svm.html>.
- [34] SINHA, U. *The Sobel and Laplacian Edge Detectors* [online]. 2017 [cit. 2020-03-11]. Dostupné z: <https://www.aishack.in/tutorials/sobel-laplacian-edge-detectors/>.
- [35] SKIMAGE. *Module: feature.texture - greycomatrix* [online]. 2020 [cit. 2020-02-17]. Dostupné z: <https://scikit-image.org/docs/0.7.0/api/skimage.feature.texture.html>.
- [36] SZEWCZYK, R., GRABOWSKI, K., NAPIERALSKA, M., SANKOWSKI, W., ZUBERT, M. et al. *A reliable iris recognition algorithm based on reverse biorthogonal wavelet transform* [online]. 2012 [cit. 2020-03-10]. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S0167865511002698#!>
- [37] VONESCH, C., BLU, T. a UNSER, M. *Generalized biorthogonal Daubechies wavelets* [online]. 2005 [cit. 2020-03-10]. Dostupné z: <https://www.ee.cuhk.edu.hk/~tblu/monsite/pdfs/vonesch0502.pdf>.
- [38] ZAGHETTO, C., MENDELSON, M., ZAGHETTO, A. a B. VIDAL, F. de. *Liveness Detection on Touchless Fingerprint Devices Using Texture Descriptors and Artificial Neural Networks* [online]. 2017 [cit. 2020-02-17]. Dostupné z: [https://www.researchgate.net/publication/320274327\\_Liveness\\_Detection\\_on\\_Touchless\\_Fingerprint\\_Devices\\_Using\\_Texture\\_Descriptors\\_and](https://www.researchgate.net/publication/320274327_Liveness_Detection_on_Touchless_Fingerprint_Devices_Using_Texture_Descriptors_and)
- [39] ZBOŘIL, F. a ZBOŘIL, F. V. *Přednáška 9 - Rozpoznávání* [online]. 2019 [cit. 2020-02-17]. Dostupné z: [https://www.fit.vutbr.cz/study/courses/IZU/private/1819izu\\_9.pdf](https://www.fit.vutbr.cz/study/courses/IZU/private/1819izu_9.pdf).